



Универзитет у Београду
Математички факултет

Семинарски рад

**Компаративна анализа
алгоритама кластеровања
у процесу семантичке
сегментације над
JobDataSet скупом
података**

Ментор:

др Мирјана
Маљковић Ружичић

Студент:

Матеја Дабовић
271/2021

Јуни 2026.

Sadržaj

1	Увод	2
2	Опис задатка	4
2.1	Екстракција, филтрирање и чишћење података .	4
2.2	Напредни инжењеринг текстуалних и категоријалних обележја	5
2.3	Математичка компресија простора и редукција димензионалности	5
2.4	Компаративно моделовање и кластеризација . . .	6
2.5	Евалуација модела и анализа вероватносне сигурности	6
3	Опис скупа података	8
3.1	Структура и типологија атрибута	8
3.2	Квалитет података и аналитички изазови	10
4	Препроцесирање података и инжењеринг обележја	11
4.1	Чишћење и токенизација текстуалног садржаја .	11
4.2	Екстракција текстуалних обележја применом TF-IDF методе	12
4.3	Енкодирање категоријалних варијабли	13
4.4	Комбиновање обележја и редукција димензионалности (Truncated SVD)	13
5	Кластеровање	15

Glava 1

Увод

Савремено дигитално доба карактерише експоненцијални раст података у готово свим сферама људског деловања, а тржиште рада и домен људских ресурса (HR) не представљају изузетак. Глобализација пословања и експанзија дигиталних платформи за запошљавање довеле су до генерисања масовних скупова података који садрже детаљне информације о радним позицијама, захтеваним вештинама, нивоима искуства и бенефитима. Међутим, највећи део ових информација налази се у форми неструктурираног или полуструктурираног текста. Традиционалне релационе базе података и класичне методе статистичке анализе нису довољно моћне да аутоматски обраде, разумеју и категоризују овакве текстуалне записе, што ствара потребу за применом напредних техника из области истраживања података (енгл. Data Mining) и обраде природног језика (енгл. Natural Language Processing - NLP).

Овај семинарски рад бави се дубинском експлоративном анализом и семантичком сегментацијом скупова података у домену тржишта рада, са специфичним фокусом на скуп података JobDataSet. Реч је о масовном скупу који симулира реалне огласе за посао, спајајући нумеричке, категоричке и обимне текстуалне атрибуте. Главни циљ истраживања је примена метода ненадгледаног машинског учења (енгл. Unsupervised Learning) ради откривања скривених структура и природних групација међу пословима, без претходно дефинисаних лабела или унапред познатих категорија.

Процес кластеризације оваквих података носи са собом значајне математичке и рачунарске изазове. Превођење не-

структурираног текста (као што су описи послова и листе вештина) у векторски простор који алгоритми могу да обрађују, захтева ригорозно препроцесирање. Коришћењем метода попут TF-IDF (енгл. Term Frequency - Inverse Document Frequency) екстракције, инстанце се пресликавају у високодимензионални простор. У таквим условима, класичне мере растојања (попут Еуклидске метрике) често губе своју дискриминативну моћ услед феномена познатог као "клетва димензионалности" (енгл. Curse of Dimensionality). Стога, овај рад посебну пажњу посвећује техникама редукције димензионалности, оптимизацији ретких матрица (енгл. Sparse Matrices) и њиховој припреми за даљу анализу.

Централни део овог рада представља компаративна анализа и евалуација чак пет различитих алгоритама за кластеризацију: K-Means, његове оптимизоване верзије Mini-Batch K-Means, Хијерархијског кластерованја (Agglomerative), алгорита заснованог на густини DBSCAN, као и вероватносног приступа применом Gaussian Mixture Models (GMM). Кроз математичко моделовање и анализу додељених кластера, испитују се предности и мане сваког од ових приступа у контексту обраде масовних текстуалних података. Крајњи резултат овог процеса јесте идентификација сродних профила послова и тржишних ниша које нису на први поглед видљиве, што има огромну практичну примену у развоју модерних алгоритама за препоруку послова (енгл. Recommender Systems) и аутоматизацију HR процеса.

Glava 2

Опис задатка

Централни задатак овог семинарског рада је пројектовање, имплементација и емпиријска евалуација робусног рачунарског пајплајна (енгл. pipeline) за масовну семантичку сегментацију и класификацију неструктурираних података са тржишта рада, примарно ослоњених на масивни скуп података JobDataSet. Проблем је дефинисан у домену ненадгледаног машинског учења, где је крајњи циљ индуковање скривене таксономије и груписање огласа за посао у кохерентне, смислене и међусобно диференциране кластере на основу њиховог текстуалног садржаја и пратећих категоријалних метаподатака.

Да би се овај комплексни аналитички циљ остварио, задатак је декомпонован на неколико међусобно повезаних и строго дефинисаних фаза:

2.1 Екстракција, филтрирање и чишћење података

Полазни скуп садржи преко 1.6 милиона записа, што представља значајан Big Data изазов са аспекта меморијског заузећа и рачунарске комплексности. Први подзадатак обухвата елиминацију ирелевантних, административних и шумних колона (као што су идентификатори, веб-сајтови, контакт телефони, географске координате и имена генералног менаџмента) које не носе семантичку вредност за саму природу радног места. Након издвајања примарних атрибута, неоп-

ходно је извршити спајање раздвојених текстуалних серија (опис посла, одговорности, захтеване вештине) у јединствени семантички контекст по свакој инстанци, чиме се креира целовита језичка репрезентација огласа.

2.2 Напредни инжењеринг текстуалних и категоријалних обележја

Текстуални сегмент задатка захтева ригорозну примену НЛП (енгл. Natural Language Processing) техника. Потребно је имплементирати систем за чишћење текста који укључује унификацију падежа (превођење у мала слова), уклањање интерпункције, нумеричких вредности и специјалних карактера. Посебан изазов чини токенизација и филтрирање семантички празног садржаја коришћењем превеликих листа стоп-речи (енгл. stopwords). Очишћени текст затим мора бити трансформисан у проређену нумеричку матрицу високе димензионалности коришћењем TF-IDF метрике, уз пажљиву оптимизацију опсега н-грама (укључујући униграме и биграме) и прагова фреквенције појављивања речи унутар корпуса.

Паралелно са обрадом текста, задатак намеће правилну обраду категоријалних серија ниског и високог интензитета (као што су улога, радно искуство и тип ангажмана). Ово подразумева импутацију недостајућих вредности и конверзију дискретних категорија у бинарни простор путем One-Hot енкодирања, након чега се врши хоризонтална фузија текстуалних и категоријалних матрица у јединствен рачунарски простор обележја.

2.3 Математичка компресија простора и редукција димензионалности

Као последица ове фузије, формира се екстремно високо-димензионални векторски простор који пати од тзв. "клетве димензионалности". Задатак поставља услов имплементације напредне матричне декомпозиције. Коришћењем методе Truncated SVD (декомпозиција на сингуларне вредности прилагођена проређеним матрицама), потребно је извршити се-

мантичку компресију простора на оптималан број латентних компоненти. Кључни подзадатак ове фазе јесте очување максималног могућег процента варијансе оригиналног скупа података, уз истовремено уклањање статистичког шума и драстично смањење рачунарске сложености за наредне алгоритме.

2.4 Компаративно моделовање и кластеризација

Језгро истраживачког задатка јесте спровођење компаративне анализе кроз имплементацију пет различитих парадигми кластеризације:

- **K-Means:** Као представник партиционих алгоритама заснованих на растојању до центроида у еуклидском простору.
- **Mini-Batch K-Means:** Као рачунарски оптимизована варијанта дизајнирана за рад са масовним Big Data скуповима података кроз стохастичке итерације.
- **Agglomerative Clustering (Хијерархијско кластеровање):** Ради инспекције структуре и креирања дендрограмских односа између послова одоздо према горе.
- **DBSCAN:** Као алгоритам заснован на густини простора, са циљем идентификације кластера произвољних облика и детекције шума (оутлијера).
- **Gaussian Mixture Models (GMM):** Као напредни вероватносни модел који напушта концепт "тврдог" додељивања и уводи "меко" кластеровање кроз пробабилистичке дистрибуције и максимизацију очекивања (ЕМ алгоритам).

2.5 Евалуација модела и анализа вероватносне сигурности

Крајњи део задатка јесте критичка евалуација перформанси примењених алгоритама. Потребно је испитати и визуел-

но представити раздвајање кластера (коришћењем напредних техника визуелизације попут t-SNE или PCA пројекција у дводимензионални простор). Посебан фокус се ставља на анализу вероватносне сигурности (енгл. confidence score) унутар GMM модела, где се кроз екстракцију максималних постериорних вероватноћа математички евалуира степен преклапања међу индукованим економским секторима и стабилност дефинисаних граница кластера.

Glava 3

Опис скупа података

За потребе овог истраживања коришћен је масовни скуп података под називом Job Dataset. Овај скуп представља свеобухватну колекцију синтетичких огласа за посао, дизајнирану са циљем да верно симулира реалне трендеве на глобалном тржишту рада. Иако су подаци синтетички (генерисани уз помоћ Python Faker библиотеке и напредних језичких модела), њихова унутрашња структура, дистрибуција категорија и комплексност текстуалних описа у потпуности одговарају стварним порталима за запошљавање, што их чини идеалним полигоном за примену техника обраде природног језика (NLP) и машинског учења.

Оригинални скуп података одликује се изузетном запремином, обухватајући 1.615.940 инстанци (огласа) и 23 иницијална атрибута. Величина датотеке која премашује 1 GB сврстава овај проблем у домен обраде великих података (енгл. Big Data), што директно условљава архитектуру рачунарског пајплајна и захтева пажљиво управљање меморијским ресурсима.

3.1 Структура и типологија атрибута

Иницијални простор обележја је изразито хетероген. Како би се подаци правилно припремили за алгоритме кластеризације, атрибути су током експлоративне анализе података (енгл. Exploratory Data Analysis - EDA) класификовани у четири логичке категорије према свом типу и семантичком значају:

- **Идентификациони и административни метаподаци:** Колоне попут Job Id, Contact Person, Contact, Job Portal и Job Posting Date. Ови атрибути представљају јединствене кључеве или трансакционе информације које не носе никакву генералну семантичку вредност о самој природи посла. Као такви, они представљају чист "шум" за алгоритме ненадгледаног учења и кандидати су за рану елиминацију.
- **Геопросторни и демографски атрибути:** Обухватају Location, Country, Latitude, Longitude и Preference. Иако су ове колоне изузетно корисне за регионалну анализу тржишта, у контексту овог рада – где је циљ проналажење кластера заснованих на стручности и опису посла – географске координате би вештачки раздвојиле идентичне послове само зато што се налазе на различитим континентима. Због тога су ови атрибути такође искључени из матрице обележја.
- **Дискретни категорички атрибути:** Колоне Experience (потребно искуство), Qualifications (образовање), Work Type (тип запослења: full-time, part-time, intern) и Role (улога). Ови атрибути носе кључне информације о сениоритету и формату посла, али захтевају математичку трансформацију (енгл. Encoding) како би постали компатибилни са метрикама растојања.
- **Неструктурирани текстуални атрибути:** Колоне Job Title, Job Description, Responsibilities, Skills и Benefits. Ово је најважнији, али и најкомплекснији део скупа података. Ови атрибути садрже богат речник специфичних стручних термина, алата и технологија. Њихова обрада захтева инжењеринг обележја којим ће се слободан текст превести у векторски облик.
- **Квази-нумерички атрибути:** Колона Salary Range (опсег плате). Иако суштински нумеричка вредност, у овом скупу је представљена као стринг (нпр. "59K–99K"), што захтева парсирање и примену регуларних израза како би се екстраховала континуална нумеричка вредност (просек опсега).

3.2 Квалитет података и аналитички изазови

Током иницијалне инспекције скупа, идентификовано је неколико критичних изазова који су диктирали даље кораке у препроцесирању:

1. **Проблем недостајућих вредности (Missing Values):** Уочено је присуство празних поља (NaN вредности) унутар одређених текстуалних и категоријских колона. Ово се мора адекватно третирати (нпр. заменом са стрингом "unknown" или празним стрингом), како алгоритми попут TF-IDF векторизатора не би пријављивали грешке током извршавања.
2. **Висока димензионалност и реткост матрице (Sparsity):** С обзиром на то да текстуални атрибути садрже десетине хиљада различитих речи, превођење оваквог корпуса у бројеве створиће матрицу са огромним бројем димензија, где ће већина вредности бити нуле. Ово директно успорава алгоритме који рачунају Еуклидско растојање.
3. **Ограничења рачунарских ресурса:** Услед чињенице да алгоритми попут Хијерархијског кластеровања имају кубну временску сложеност $O(n^3)$ и квадратну меморијску сложеност $O(n^2)$ за матрицу растојања, немогуће је процесирати свих 1.6 милиона редова у локалном рачунарском окружењу без појаве Out-Of-Memory грешке. Из тог разлога, пројекат се ослања на технике узорковања (енгл. Sampling) и ефикасну употребу оптимизованих структура података приликом изградње модела.

Glava 4

Препроцесирање података и инжењеринг обележја

У процесу истраживања података, фаза припреме и препроцесирања често представља најзахтевнији и најважнији корак. С обзиром на то да алгоритми машинског учења захтевају нумеричке улазне вредности, неопходно је трансформисати оригиналне, хетерогене податке у структурирани математички простор. У случају JobDataSet скупа података, који доминантно чини неструктурирани текст, препроцесирање је спроведено кроз четири ригорозне фазе.

4.1 Чишћење и токенизација текстуалног садржаја

Први корак у обради неструктурираних података јесте нормализација текста. Како би се објединио семантички контекст сваког огласа за посао, иницијално је извршена конкатенација садржаја колоне Job Description, Responsibilities и skills у јединствену варијаблу text. Овако добијени текст обилује шумом – интерпункцијским знацима, бројевима и граматичким варијацијама које не носе суштинску информацију о радном месту.

Процес чишћења (енгл. Text Cleansing) имплементиран је на следећи начин:

1. **Унификација падежа (Lowercasing):** Сав текст је конвертован у мала слова како би алгоритам третирао речи попут Data", DATA"и data"као идентичне токене.
2. **Филтрирање регуларним изразима (Regex):** Применом обрасца [^a-z\s] елиминисани су сви карактери који не припадају енглеском алфabetу (бројеви, специјални симболи, ознаке валута).
3. **Токенизација:** Текст је разбијен на секвенцу појединачних речи (токена) коришћењем функције word_tokenize из NLTK (Natural Language Toolkit) библиотеке.
4. **Уклањање стоп-речи (Stopwords Removal):** Избачене су честе речи енглеског језика (као што су предлози, везници и чланови: and, the, is, in), које се појављују у готово сваком документу и немају дискриминативну моћ у издвајању специфичних кластера.

4.2 Екстракција текстуалних обележја применом TF-IDF методе

Након токенизације, очишћени текст мора бити векторски репрезентован. Уместо једноставног бројања фреквенције речи (енгл. Bag of Words), примењена је напреднија TF-IDF (Term Frequency - Inverse Document Frequency) метрика. Ова метода не само да узима у обзир колико се често нека реч појављује у конкретном огласу, већ и кажњава речи које су превише заступљене у целом корпусу података.

TF-IDF вредност се рачуна као производ две компоненте:

1. **Фреквенција термина (TF):** Мери учесталост термина t у документу d .

$$TF(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}}$$

2. **Инверзна фреквенција документа (IDF):** Мери информациону вредност термина на нивоу целог корпуса D величине N .

$$IDF(t, D) = \log \frac{N}{|\{d \in D : t \in d\}|}$$

4.3 Енкодирање категоријалних варијабли

Поред текста, огласи за посао су дефинисани и категоријалним варијаблама: Role, Experience и Work Type. С обзиром на то да алгоритми кластеризације рачунају метрике растојања, ове категорије се не смеју презентовати као нумерички лабелли (0, 1, 2...), јер би то имплицирало вештачко уређење (нпр. да је категорија 2 већа од категорије 1).

Стога је примењено One-Hot енкодирање које сваку јединствену категорију претвара у засебну бинарну колону (0 или 1). Да би се избегао проблем перфектне мултиколинearности (енгл. Dummy Variable Trap), из сваке групе категорија избачена је прва колона (drop_first=True). Спајањем ових колона добијена је категоријална матрица од 426 димензија.

4.4 Комбиновање обележја и редукција димензионалности (Truncated SVD)

Спајањем TF-IDF матрице и One-Hot матрице добијен је високодимензионални простор од 5426 атрибута. У овако великим просторима, мера попут Еуклидског растојања:

$$d(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

постаје неадекватна јер растојања између свих парова тачака конвергирају ка сличним вредностима (проблем познат као Curse of Dimensionality). Додатно, обрада преко 5400 димензија за 1.6 милиона редова би захтевала недостижне меморијске ресурсе.

Уместо стандардне Анализе главних компоненти (PCA), која захтева центрирање података и тиме уништава проређеност матрице (што би тренутно препунило RAM меморију), примењена је Truncated SVD (Singular Value Decomposition) метода. Овај алгоритам факторише оригиналну матрицу X у производ три матрице:

$$X \approx U \Sigma V^T$$

и задржава само k најзначајнијих сингуларних вредности.

У овом раду, број димензија је редукован на $k=100$ компоненти. Емпиријском анализом је утврђено да ових 100 компоненти објашњава 62.71% кумулативне варијансе оригиналног скупа података. Овакав ниво сачуване информације представља одличан компромис, јер елиминише семантички шум (тзв. репетативне или ретке термине), док истовремено експоненцијално убрзава време извршавања алгоритама за кластеризацију који следе у наредном поглављу.

Glava 5

Кластеровање