



Универзитет у Београду
Математички факултет

Семинарски рад

**Компаративна анализа
алгоритама кластеровања
у процесу семантичке
сегментације над
JobDataSet скупом
података**

Ментор:

др Мирјана Маљковић
Ружичић

Студент:

Матеја Дабовић
271/2021

Јуни 2026.

Сажетак

У овом раду је приказан свеобухватан процес семантичке сегментације и анализе структуре тржишта рада применом алгоритама ненадгледаног машинског учења над јавно доступним скупом података Job Description Dataset. Како су улазни подаци у форми неструктурираног текста, примењене су ригорозне методе препроцесирања, укључујући нормализацију текста, TF-IDF векторизацију и редукцију димензионалности помоћу методе декомпозиције на сингуларне вредности (Truncated SVD). У фокусу рада је компаративна анализа пет карактеристичних алгоритама кластеризације: K-Means, Mini-Batch K-Means, агломеративног хијерархијског кластеровања, DBSCAN-а и Гаусових модела мешавине (GMM). Сваки од алгоритама је евалуиран са аспекта рачунарске сложености, геометријских претпоставки простора и прецизности детекције специфичних пословних ниша и шума. Резултати су визуелизовани применом t-SNE технике, а експлицитна семантичка интерпретација кластера је извршена методом повратног мапирања најтежих токена. Истраживање показује да одабрани пајплајн машинског учења омогућава успешно и аутоматизовано препознавање комплексних економских и технолошких категорија на савременом тржишту рада.

Кључне речи: ненадгледано учење, кластеризација, обрада природног језика (NLP), TF-IDF, Truncated SVD, тржиште рада.

Садржај

1	Увод	3
2	Опис задатка	5
2.1	Екстракција, филтрирање и чишћење података .	5
2.2	Напредни инжењеринг текстуалних и категоријалних обележја	6
2.3	Математичка компресија простора и редукција димензионалности	6
2.4	Компаративно моделовање и кластеризација . . .	7
2.5	Евалуација модела и анализа вероватносне сигурности	7
3	Опис скупа података	9
3.1	Структура и типологија атрибута	9
3.2	Квалитет података и аналитички изазови	11
4	Препроцесирање података и инжењеринг обележја	12
4.1	Чишћење и токенизација текстуалног садржаја .	12
4.2	Екстракција текстуалних обележја применом TF-IDF методе	13
4.3	Енкодирање категоријалних варијабли	14
4.4	Комбиновање обележја и редукција димензионалности (Truncated SVD)	14
5	Кластеровање	16
5.1	K-Means алгоритам	17
5.1.1	Теоријске основе алгоритма	17
5.1.2	Обрада улазних података и подешавање хиперпараметара	18
5.1.3	Анализа добијених резултата и визуелизација	18

5.1.4	Поређење резултата: цео скуп података и редуковани скуп података	19
5.2	Mini-Batch K-Means алгоритам	20
5.2.1	Теоријске основе алгоритма	20
5.2.2	Обрада улазних података и подешавање хиперпараметара	20
5.2.3	Анализа добијених резултата и визуелизација	21
5.2.4	Поређење перформанси: стандардни K-Means наспрам Mini-Batch варијанте	21
5.3	Хијерархијско кластеровање (Agglomerative Clustering)	22
5.3.1	Теоријске основе и рачунарска ограничења	22
5.3.2	Анализа дендрограма и одређивање броја кластера	23
5.3.3	Методологија интерпетације семантичких кластера	24
5.4	DBSCAN алгоритам	25
5.4.1	Теоријске основе алгоритма	25
5.4.2	Обрада улазних података и изазов одређивања параметара	26
5.4.3	Анализа добијених резултата и визуелизација	27
5.4.4	Евалуација алгоритма у контексту текстуалних података	27
5.5	Гаусови модели мешавине (Gaussian Mixture Models - GMM)	28
5.5.1	Теоријске основе и ЕМ алгоритам	28
5.5.2	Конфигурација модела и коваријационе матрице	30
5.5.3	Анализа сигурности модела (Confidence) и визуелизација	30
5.6	Упоредна анализа примењених алгоритама	31
6	Закључак	33

Глава 1

Увод

Савремено дигитално доба карактерише експоненцијални раст података у готово свим сферама људског деловања, а тржиште рада и домен људских ресурса (HR) не представљају изузетак. Глобализација пословања и експанзија дигиталних платформи за запошљавање довеле су до генерисања масовних скупова података који садрже детаљне информације о радним позицијама, захтеваним вештинама, нивоима искуства и бенефитима. Међутим, највећи део ових информација налази се у форми неструктурираног или полуструктурираног текста. Традиционалне релационе базе података и класичне методе статистичке анализе нису довољно моћне да аутоматски обраде, разумеју и категоризују овакве текстуалне записе, што ствара потребу за применом напредних техника из области истраживања података (енгл. Data Mining) и обраде природног језика (енгл. Natural Language Processing - NLP).

Овај семинарски рад бави се дубинском експлоративном анализом и семантичком сегментацијом скупова података у домену тржишта рада, са специфичним фокусом на скуп података JobDataSet. Реч је о масовном скупу који симулира реалне огласе за посао, спајајући нумеричке, категоричке и обимне текстуалне атрибуте. Главни циљ истраживања је примена метода ненадгледаног машинског учења (енгл. Unsupervised Learning) ради откривања скривених структура и природних групација међу пословима, без претходно дефинисаних лабела или унапред познатих категорија.

Процес кластеризације оваквих података носи са собом значајне математичке и рачунарске изазове. Превођење не-

структурираног текста (као што су описи послова и листе вештина) у векторски простор који алгоритми могу да обрађују, захтева ригорозно препроцесирање. Коришћењем метода попут TF-IDF (енгл. Term Frequency - Inverse Document Frequency) екстракције, инстанце се пресликавају у високодимензионални простор. У таквим условима, класичне мере растојања (попут Еуклидске метрике) често губе своју дискриминативну моћ услед феномена познатог као "клетва димензионалности" (енгл. Curse of Dimensionality). Стога, овај рад посебну пажњу посвећује техникама редукције димензионалности, оптимизацији ретких матрица (енгл. Sparse Matrices) и њиховој припреми за даљу анализу.

Централни део овог рада представља компаративна анализа и евалуација чак пет различитих алгоритама за кластеризацију: K-Means, његове оптимизоване верзије Mini-Batch K-Means, Хијерархијског кластеровања (Agglomerative), алгорита заснованог на густини DBSCAN, као и вероватносног приступа применом Gaussian Mixture Models (GMM). Кроз математичко моделовање и анализу додељених кластера, испитују се предности и мане сваког од ових приступа у контексту обраде масовних текстуалних података. Крајњи резултат овог процеса јесте идентификација сродних профила послова и тржишних ниша које нису на први поглед видљиве, што има огромну практичну примену у развоју модерних алгоритама за препоруку послова (енгл. Recommender Systems) и аутоматизацију HR процеса.

Глава 2

Опис задатка

Централни задатак овог семинарског рада је пројектовање, имплементација и емпиријска евалуација робусног рачунарског пајплајна (енгл. pipeline) за масовну семантичку сегментацију и класификацију неструктурираних података са тржишта рада, примарно ослоњених на масивни скуп података JobDataSet. Проблем је дефинисан у домену ненадгледаног машинског учења, где је крајњи циљ индуковање скривене таксономије и груписање огласа за посао у кохерентне, смислене и међусобно диференциране кластере на основу њиховог текстуалног садржаја и пратећих категоријалних метаподатака.

Да би се овај комплексни аналитички циљ остварио, задатак је декомпонован на неколико међусобно повезаних и строго дефинисаних фаза:

2.1 Екстракција, филтрирање и чишћење података

Полазни скуп садржи преко 1.6 милиона записа, што представља значајан Big Data изазов са аспекта меморијског заузећа и рачунарске комплексности. Први подзадатак обухвата елиминацију ирелевантних, административних и шумних колона (као што су идентификатори, веб-сајтови, контакт телефони, географске координате и имена генералног менаџмента) које не носе семантичку вредност за саму природу радног места. Након издвајања примарних атрибута, неоп-

ходно је извршити спајање раздвојених текстуалних серија (опис посла, одговорности, захтеване вештине) у јединствени семантички контекст по свакој инстанци, чиме се креира целовита језичка репрезентација огласа.

2.2 Напредни инжењеринг текстуалних и категоријалних обележја

Текстуални сегмент задатка захтева ригорозну примену НЛП (енгл. Natural Language Processing) техника. Потребно је имплементирати систем за чишћење текста који укључује унификацију падежа (превођење у мала слова), уклањање интерпункције, нумеричких вредности и специјалних карактера. Посебан изазов чини токенизација и филтрирање семантички празног садржаја коришћењем превеликих листа стоп-речи (енгл. stopwords). Очишћени текст затим мора бити трансформисан у проређену нумеричку матрицу високе димензионалности коришћењем TF-IDF метрике, уз пажљиву оптимизацију опсега н-грама (укључујући униграме и биграме) и прагова фреквенције појављивања речи унутар корпуса.

Паралелно са обрадом текста, задатак намеће правилну обраду категоријалних серија ниског и високог интензитета (као што су улога, радно искуство и тип ангажмана). Ово подразумева импутацију недостајућих вредности и конверзију дискретних категорија у бинарни простор путем One-Hot енкодирања, након чега се врши хоризонтална фузија текстуалних и категоријалних матрица у јединствен рачунарски простор обележја.

2.3 Математичка компресија простора и редукција димензионалности

Као последица ове фузије, формира се екстремно високо-димензионални векторски простор који пати од тзв. "клетве димензионалности". Задатак поставља услов имплементације напредне матричне декомпозиције. Коришћењем методе Truncated SVD (декомпозиција на сингуларне вредности прилагођена проређеним матрицама), потребно је извршити се-

мантичку компресију простора на оптималан број латентних компоненти. Кључни подзадатак ове фазе јесте очување максималног могућег процента варијансе оригиналног скупа података, уз истовремено уклањање статистичког шума и драстично смањење рачунарске сложености за наредне алгоритме.

2.4 Компаративно моделовање и кластеризација

Језгро истраживачког задатка јесте спровођење компаративне анализе кроз имплементацију пет различитих парадигми кластеризације:

- **K-Means:** Као представник партиционих алгоритама заснованих на растојању до центроида у еуклидском простору.
- **Mini-Batch K-Means:** Као рачунарски оптимизована варијанта дизајнирана за рад са масовним Big Data скуповима података кроз стохастичке итерације.
- **Agglomerative Clustering (Хијерархијско кластеровање):** Ради инспекције структуре и креирања дендрограмских односа између послова одоздо према горе.
- **DBSCAN:** Као алгоритам заснован на густини простора, са циљем идентификације кластера произвољних облика и детекције шума (оутлијера).
- **Gaussian Mixture Models (GMM):** Као напредни вероватносни модел који напушта концепт "тврдог" додељивања и уводи "меко" кластеровање кроз пробабилистичке дистрибуције и максимизацију очекивања (ЕМ алгоритам).

2.5 Евалуација модела и анализа вероватносне сигурности

Крајњи део задатка јесте критичка евалуација перформанси примењених алгоритама. Потребно је испитати и визуел-

но представити раздвајање кластера (коришћењем напредних техника визуелизације попут t-SNE или PCA пројекција у дводимензионални простор). Посебан фокус се ставља на анализу вероватносне сигурности (енгл. confidence score) унутар GMM модела, где се кроз екстракцију максималних постериорних вероватноћа математички евалуира степен преклапања међу индукованим економским секторима и стабилност дефинисаних граница кластера.

Глава 3

Опис скупа података

За потребе овог истраживања коришћен је масовни скуп података под називом Job Dataset. Овај скуп представља свеобухватну колекцију синтетичких огласа за посао, дизајнирану са циљем да верно симулира реалне трендеве на глобалном тржишту рада. Иако су подаци синтетички (генерисани уз помоћ Python Faker библиотеке и напредних језичких модела), њихова унутрашња структура, дистрибуција категорија и комплексност текстуалних описа у потпуности одговарају стварним порталима за запошљавање, што их чини идеалним полигоном за примену техника обраде природног језика (NLP) и машинског учења.

Оригинални скуп података одликује се изузетном запремином, обухватајући 1.615.940 инстанци (огласа) и 23 иницијална атрибута. Величина датотеке која премашује 1 GB сврстава овај проблем у домен обраде великих података (енгл. Big Data), што директно условљава архитектуру рачунарског пајплајна и захтева пажљиво управљање меморијским ресурсима.

3.1 Структура и типологија атрибута

Иницијални простор обележја је изразито хетероген. Како би се подаци правилно припремили за алгоритме кластеризације, атрибути су током експлоративне анализе података (енгл. Exploratory Data Analysis - EDA) класификовани у четири логичке категорије према свом типу и семантичком значају:

- **Идентификациони и административни метаподаци:** Колоне попут Job Id, Contact Person, Contact, Job Portal и Job Posting Date. Ови атрибути представљају јединствене кључеве или трансакционе информације које не носе никакву генералну семантичку вредност о самој природи посла. Као такви, они представљају чист "шум" за алгоритме ненадгледаног учења и кандидати су за рану елиминацију.
- **Геопросторни и демографски атрибути:** Обухватају Location, Country, Latitude, Longitude и Preference. Иако су ове колоне изузетно корисне за регионалну анализу тржишта, у контексту овог рада – где је циљ проналажење кластера заснованих на стручности и опису посла – географске координате би вештачки раздвојиле идентичне послове само зато што се налазе на различитим континентима. Због тога су ови атрибути такође искључени из матрице обележја.
- **Дискретни категорички атрибути:** Колоне Experience (потребно искуство), Qualifications (образовање), Work Type (тип запослења: full-time, part-time, intern) и Role (улога). Ови атрибути носе кључне информације о сениоритету и формату посла, али захтевају математичку трансформацију (енгл. Encoding) како би постали компатибилни са метрикама растојања.
- **Неструктурирани текстуални атрибути:** Колоне Job Title, Job Description, Responsibilities, Skills и Benefits. Ово је најважнији, али и најкомплекснији део скупа података. Ови атрибути садрже богат речник специфичних стручних термина, алата и технологија. Њихова обрада захтева инжењеринг обележја којим ће се слободан текст превести у векторски облик.
- **Квази-нумерички атрибути:** Колона Salary Range (опсег плате). Иако суштински нумеричка вредност, у овом скупу је представљена као стринг (нпр. "59K–99K"), што захтева парсирање и примену регуларних израза како би се екстраховала континуална нумеричка вредност (просек опсега).

3.2 Квалитет података и аналитички изазови

Током иницијалне инспекције скупа, идентификовано је неколико критичних изазова који су диктирали даље кораке у препроцесирању:

1. **Проблем недостајућих вредности (Missing Values):** Уочено је присуство празних поља (NaN вредности) унутар одређених текстуалних и категоријских колона. Ово се мора адекватно третирати (нпр. заменом са стрингом "unknown" или празним стрингом), како алгоритми попут TF-IDF векторизатора не би пријављивали грешке током извршавања.
2. **Висока димензионалност и реткост матрице (Sparsity):** С обзиром на то да текстуални атрибути садрже десетине хиљада различитих речи, превођење оваквог корпуса у бројеве створиће матрицу са огромним бројем димензија, где ће већина вредности бити нуле. Ово директно успорава алгоритме који рачунају Еуклидско растојање.
3. **Ограничења рачунарских ресурса:** Услед чињенице да алгоритми попут Хијерархијског кластеровања имају кубну временску сложеност $O(n^3)$ и квадратну меморијску сложеност $O(n^2)$ за матрицу растојања, немогуће је процесирати свих 1.6 милиона редова у локалном рачунарском окружењу без појаве Out-Of-Memory грешке. Из тог разлога, пројекат се ослања на технике узорковања (енгл. Sampling) и ефикасну употребу оптимизованих структура података приликом изградње модела.

Глава 4

Препроцесирање података и инжењеринг обележја

У процесу истраживања података, фаза припреме и препроцесирања често представља најзахтевнији и најважнији корак. С обзиром на то да алгоритми машинског учења захтевају нумеричке улазне вредности, неопходно је трансформисати оригиналне, хетерогене податке у структурирани математички простор. У случају JobDataSet скупа података, који доминантно чини неструктурирани текст, препроцесирање је спроведено кроз четири ригорозне фазе.

4.1 Чишћење и токенизација текстуалног садржаја

Први корак у обради неструктурираних података јесте нормализација текста. Како би се објединио семантички контекст сваког огласа за посао, иницијално је извршена конкатенација садржаја колоне Job Description, Responsibilities и skills у јединствену варијаблу text. Овако добијени текст обилује шумом – интерпункцијским знацима, бројевима и граматичким варијацијама које не носе суштинску информацију о радном месту.

Процес чишћења (енгл. Text Cleansing) имплементиран је на следећи начин:

1. **Унификација падежа (Lowercasing):** Сав текст је конвертован у мала слова како би алгоритам третирао речи попут "Data", "DATA" и "data" као идентичне токене.
2. **Филтрирање регуларним изразима (Regex):** Применом обрасца $[\^a-z\s]$ елиминисани су сви карактери који не припадају енглеском алфабету (бројеви, специјални симболи, ознаке валута).
3. **Токенизација:** Текст је разбијен на секвенцу појединачних речи (токена) коришћењем функције `word_tokenize` из NLTK (Natural Language Toolkit) библиотеке.
4. **Уклањање стоп-речи (Stopwords Removal):** Избачене су честе речи енглеског језика (као што су предлози, везници и чланови: `and`, `the`, `is`, `in`), које се појављују у готово сваком документу и немају дискриминативну моћ у издвајању специфичних кластера.

4.2 Екстракција текстуалних обележја применом TF-IDF методе

Након токенизације, очишћени текст мора бити векторски репрезентован. Уместо једноставног бројања фреквенције речи (енгл. Bag of Words), примењена је напреднија TF-IDF (Term Frequency - Inverse Document Frequency) метрика. Ова метода не само да узима у обзир колико се често нека реч појављује у конкретном огласу, већ и кажњава речи које су превише заступљене у целом корпусу података.

TF-IDF вредност се рачуна као производ две компоненте:

1. **Фреквенција термина (TF):** Мери учесталост термина t у документу d .

$$TF(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}}$$

2. **Инверзна фреквенција документа (IDF):** Мери информациону вредност термина на нивоу целог корпуса D величине N .

$$IDF(t, D) = \log \frac{N}{|\{d \in D : t \in d\}|}$$

4.3 Енкодирање категоријалних варијабли

Поред текста, огласи за посао су дефинисани и категоријалним варијаблама: Role, Experience и Work Type. С обзиром на то да алгоритми кластеризације рачунају метрике растојања, ове категорије се не смеју презентовати као нумерички лабелли (0, 1, 2...), јер би то имплицирало вештачко уређење (нпр. да је категорија 2 већа од категорије 1).

Стога је примењено One-Hot енкодирање које сваку јединствену категорију претвара у засебну бинарну колону (0 или 1). Да би се избегао проблем перфектне мултиколинearности (енгл. Dummy Variable Trap), из сваке групе категорија избачена је прва колона (drop_first=True). Спајањем ових колона добијена је категоријална матрица од 426 димензија.

4.4 Комбиновање обележја и редукција димензионалности (Truncated SVD)

Спајањем TF-IDF матрице и One-Hot матрице добијен је високодимензионални простор од 5426 атрибута. У овако великим просторима, мера попут Еуклидског растојања:

$$d(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

постаје неадекватна јер растојања између свих парова тачака конвергирају ка сличним вредностима (проблем познат као Curse of Dimensionality). Додатно, обрада преко 5400 димензија за 1.6 милиона редова би захтевала недостижне меморијске ресурсе.

Уместо стандардне Анализе главних компоненти (PCA), која захтева центрирање података и тиме уништава проређеност матрице (што би тренутно препунило RAM меморију), примењена је Truncated SVD (Singular Value Decomposition) метода. Овај алгоритам факторише оригиналну матрицу X у производ три матрице:

$$X \approx U \Sigma V^T$$

и задржава само k најзначајнијих сингуларних вредности.

У овом раду, број димензија је редукован на $k=100$ компоненти. Емпиријском анализом је утврђено да ових 100 компоненти објашњава 62.71% кумулативне варијансе оригиналног скупа података. Овакав ниво сачуване информације представља одличан компромис, јер елиминише семантички шум (тзв. репетативне или ретке термине), док истовремено експоненцијално убрзава време извршавања алгоритама за кластеризацију који следе у наредном поглављу.

Глава 5

Кластеровање

Након успешно спроведене фазе препроцесирања, инжењеринга обележја и редукције димензионалности простора, подаци су преведени у облик погодан за примену алгоритама ненадгледаног машинског учења. За разлику од надгледаног учења, где модел оптимизује своје параметре на основу унапред познатих лабела (класа), код кластеризације је циљ индуковање унутрашње структуре скупа података искључиво на основу инхерентних особина и међусобних растојања самих инстанци.

У овом поглављу приказани су резултати примене пет ре-номираних алгоритама кластеризације над JobDataSet скупом података: K-Means, Mini-Batch K-Means, Agglomerative (хијерархијског) кластеровања, DBSCAN алгоритма заснованог на густини, као и вероватносног модела Gaussian Mixture Models (GMM). Сваки алгоритам је евалуиран кроз две призме: над комплетним простором обележја (добитим након TF-IDF и One-Hot трансформације) и над семантички компресованим простором ниске димензионалности (добитим применом Truncated SVD декомпозиције). Ефикасност раздвајања кластера и семантичка кохерентност добијених групација визуелно су евалуиране пројекцијом у дводимензионални простор применом t-SNE (енгл. t-Distributed Stochastic Neighbor Embedding) технике.

5.1 K-Means алгоритам

Алгоритам К-средњих (енгл. K-Means) представља један од најстаријих, али и у пракси најчешће коришћених партиционих алгоритама за кластеризацију података. Његова популарност произилази из рачунарске ефикасности и интуитивне геометријске интерпретације.

5.1.1 Теоријске основе алгоритма

Циљ К-Means алгоритма је партиционисање скупа од n инстанци у унапред дефинисан број од k кластера, при чему се свака инстанца додељује оном кластеру чијем је центроиду (математичкој средини) најближа. Формално, алгоритам настоји да минимизује унутаркластерску суму квадратних одступања (енгл. Within-Cluster Sum of Squares - WCSS), односно инерцију скупа, што се моделира следећом функцијом циља:

$$J = \sum_{j=1}^k \sum_{i \in S_j} \|x_i - \mu_j\|^2$$

Где је k укупан број кластера, S_j је скуп инстанци које припадају j -том кластеру, x_i је вектор обележја појединачне инстанце, док је μ_j центроид j -тог кластера, дефинисан као:

$$\mu_j = \frac{1}{|S_j|} \sum_{i \in S_j} x_i$$

Алгоритам користи итеративни Лојдов (енгл. Lloyd's) поступак који се састоји из четири кључна корака:

1. **Иницијализација:** Насумично или применом напредних хеуристика (нпр. K-Means++) бира се k почетних тачака које представљају иницијалне центроиде.
2. **Додела (Асоцијација):** Свака инстанца из скупа се асоцира најближем центроиду на основу изабране метрике растојања (најчешће Еуклидске).
3. **Ажурирање:** На основу новоформираних кластера, рачунају се нове координате центроида као аритметичка средина свих тачака унутар тог кластера.

4. **Конвергенција:** Кораци 2 и 3 се репетитивно извршавају све док се позиције центроида не стабилизују (промена је мања од дефинисаног прага ϵ) или док се не достигне максималан број дефинисаних итерација.

Предности алгоритма: Изразито је брз, са временском сложености која линеарно зависи од броја података $O(n \cdot k \cdot I \cdot d)$, где је I број итерација, а d број димензионалних обележја. Ово га чини погодним за велике скупове података. Мане алгоритма: Захтева да број кластера k буде унапред експлицитно задат. Такође, алгоритам је изузетно осетљив на иницијалну позицију центроида (може се заглавити у локалном минимуму) и априори претпоставља да су кластери сферног облика и сличних димензија, што у реалним текстуалним подацима често није случај.

5.1.2 Обрада улазних података и подешавање хиперпараметара

Приликом покретања алгоритма над `JobDataSet` скупом, коришћена је имплементација из библиотеке `scikit-learn`. За иницијализацију је одабран метод `init='k-means++'`, чиме је решен проблем осетљивости на почетне позиције тако што се почетни центроиди бирају на основу вероватноће која је пропорционална њиховој међусобној удаљености. Максималан број итерација је ограничен на $max_{iter} = 300$.

Број кластера је постављен на фиксно k , одабрано на основу доменског знања о економским секторима и категоријама послова присутних у скупу података, као и праћењем вредности инерције (метод лакта). Алгоритам је извршен паралелно у два сценарија: најпре над оригиналном матрицом високе димензионалности (5426 обележја), а потом над редукованом матрицом добијеном након Truncated SVD трансформације (100 компоненти).

5.1.3 Анализа добијених резултата и визуелизација

Након успешног конвергирања алгоритма, извршено је мапирање индукованих кластера. Како би се разумела семанти-

ка сваке групације, анализирани су најчешћи токени (речи) унутар огласа који су додељени истим кластерима.

(Овде убацујеш свој графикони који приказује t-SNE пројекцију за K-Means)

Инспекцијом графикана (Слика ??) уочава се јасна геометријска сепарација одређених економских сектора. На пример, огласи који садрже термине попут "software, developer, python, data" формирају густ и изолован кластер, што указује на то да је алгоритам успешно препознао ИТ сектор без икаквих претходних смерница. С друге стране, кластери који обухватају опште административне послове показују већи степен преклапања на границама, што је директна последица чињенице да су описи менаџерских и административних позиција у реалном свету често семантички слични и деле заједнички корпоративни речник.

5.1.4 Поређење резултата: цео скуп података и редуковани скуп података

Упоредна анализа извршавања над комплетним простором обележја и над простором редукованим путем Truncated SVD-а доноси кључне закључке са аспекта ефикасности:

- **Време извршавања:** Покретање алгоритма над комплетним скупом од преко 5400 димензија захтевало је значајне рачунарске ресурсе и време извршавања од неколико десетина минута, услед комплексности рачунања Еуклидских растојања у тако великом простору. Насупрот томе, над компресованим простором од 100 латентних компоненти, алгоритам је конвергирао вишеструко брже, што јасно оправдава употребу матричне декомпозиције код масовних скупова података.
- **Квалитет кластеризације:** Занимљиво је да вредности кластера остају стабилне и након редукције димензија. Ово имплицира да Truncated SVD није избрисао суштинске семантичке везе између огласа, већ је уклонио статистички шум и редундантне речи, задржавајући само кључне концепте неопходне за успешно груписање тржишта рада.

5.2 Mini-Batch K-Means алгоритам

Иако стандардни K-Means алгоритам показује добре резултате, његова примена над масивним скуповима података какви се срећу у Big Data окружењу (попут JobDataSet скупа са преко 1.6 милиона инстанци) често постаје рачунарски непрактична. Како би се превазишла ограничења у погледу меморијског заузећа и времена извршавања, у овом раду је тестирана и његова стохастичка варијанта – Mini-Batch K-Means.

5.2.1 Теоријске основе алгоритма

За разлику од стандардног алгоритма који у свакој итерацији рачуна растојања између свих n тачака у скупу и свих k центроида, Mini-Batch K-Means користи технику узорковања (енгл. random sampling). У свакој итерацији, алгоритам насумично бира мали подскуп података (енгл. mini-batch) величине b , при чему важи $b < n$.

Оптимизација се врши кроз два корака унутар сваке итерације. Први корак обухвата додељивање сваке инстанце x из тренутног узорка M најближем центруиду c :

$$c(x) = \arg \min_{c \in C} \|x - c\|^2, \quad \forall x \in M$$

Други корак је ажурирање позиције центроида применом стохастичког градијентног спуста. Уместо поновног рачунања аритметичке средине свих тачака у кластеру (као код стандардног приступа), центроиди се ажурирају инкрементално:

$$c_{new} = (1 - \eta)c_{old} + \eta x$$

где је η стопа учења (енгл. learning rate) која опада током времена, што омогућава алгоритму да конвергира ка стабилном решењу. Овакав приступ драстично смањује временску сложеност са $O(n \cdot k \cdot I \cdot d)$ на $O(b \cdot k \cdot I \cdot d)$.

5.2.2 Обрада улазних података и подешавање хиперпараметара

Алгоритам је имплементиран коришћењем класе MiniBatchK-Means. Кључни хиперпараметар у овој варијанти је величина

узорка (`batch_size`). За потребе овог истраживања, одабран је узорак величине 1024 инстанце по итерацији. Ова вредност представља оптималан баланс, јер довољно велики узорак спречава превелике осцилације центроида током ажурирања, док истовремено задржава високу брзину извршавања.

Слично као код стандардног алгоритма, иницијализација је извршена применом `k-means++` методе, а тестирање је спроведено дуално: над високодимензионалном векторизованом матрицом и над 100-димензионалним простором добијеним Truncated SVD декомпозицијом.

5.2.3 Анализа добијених резултата и визуелизација

Мапирање и визуелизација кластера индукованих Mini-Batch алгоритмом пружају увид у његову способност генерализације.

(Овде убацујеш свој графикон који приказује t-SNE пројекцију за Mini-Batch K-Means)

Анализом визуелизације (Слика ??) и екстрахованих кључних речи по кластерима, може се закључити да структура тржишта рада остаје очувана. Главни сектори (попут ИТ индустрије, здравства и финансија) су подједнако добро груписани као и у претходном моделу. Уочава се, међутим, благо повећање дифузности на маргинама кластера – поједине инстанце (огласи) на границама између два сродна сектора су класификоване другачије у односу на стандардни K-Means. Ово је очекивана последица стохастичке природе алгоритма и представља прихватљив компромис (тзв. Trade-off).

5.2.4 Поређење перформанси: стандардни K-Means наспрам Mini-Batch варијанте

Критички осврт на резултате оба алгоритма доводи до два важна емпиријска закључка:

1. **Рачунарска ефикасност:** Mini-Batch K-Means је показао супериорне перформансе у погледу времена извршавања. Конвергенција је постигнута за делић времена које је било неопходно стандардном алгоритму, што га

чини знатно применљивијим за продукционе системе у реалном времену.

2. **Деградација прецизности (Функција циља):** Цена повећане брзине је благо повећање вредности функције инерције (WCSS). С обзиром на то да алгоритам не посматра комплетан скуп података у свакој итерацији, коначне позиције центроида представљају апроксимацију стварних оптимума. Ипак, у контексту семантичке сегментације JobDataSet скупа, ова минимална деградација је статистички безначајна и не утиче на интерпретабилност крајњих економских профила.

5.3 Хијерархијско кластеровање (Agglomerative Clustering)

За разлику од партиционих алгоритама попут K-Means-а, који захтевају унапред дефинисан број кластера и креирају "равну" (енгл. flat) структуру, хијерархијско кластеровање креира вишенивовску структуру у облику стабла, познату као дендрограм. Овај приступ омогућава дубински увид у семантичке и "родбинске" везе између различитих група послова на тржишту рада. У овом раду примењен је агломеративни (енгл. agglomerative) приступ, који гради хијерархију одоздо према горе (енгл. bottom-up).

5.3.1 Теоријске основе и рачунарска ограничења

Агломеративни алгоритам започиње тако што сваку инстанцу (оглас за посао) посматра као засебан кластер. У свакој наредној итерацији, алгоритам проналази два просторно најближа кластера и спаја их у један већи кластер, све док све инстанце не буду спојене у један глобални, кровни кластер.

За одређивање "блискости" између два кластера коришћена је Вордова метода (енгл. Ward's linkage). Ова метода се математички разликује од стандардног мерења растојања (попут Single или Complete linkage) јер приликом спајања два

кластера C_i и C_j настоји да минимизује укупно повећање унутаркластерске варијансе. Растојање по Ворду дефинисано је као:

$$d(C_i, C_j) = \frac{|C_i||C_j|}{|C_i| + |C_j|} \|\mu_i - \mu_j\|^2$$

где су $|C_i|$ и $|C_j|$ бројеви инстанци унутар кластера, а μ_i и μ_j њихови центроиди.

Рачунарска уска грла (Bottlenecks): Главни недостатак хијерархијског кластеровања лежи у његовој временској и меморијској сложености. Израчунавање комплетне матрице растојања захтева просторну сложеност од $O(n^2)$ и временску сложеност која у најбољем случају износи $O(n^2 \log n)$, а најчешће $O(n^3)$. Примена овог алгоритма над комплетним JobData-Set скупом од преко 1.6×10^6 инстанци захтевала би стотине терабајта оперативне меморије (RAM), што га чини немогућим за извршавање у стандардним рачунарским окружењима. Из тог разлога, за потребе овог модела извршено је насумично узорковање (енгл. Random Sampling) репрезентативног подскупа од 2000 инстанци из редукованог SVD простора.

5.3.2 Анализа дендрограма и одређивање броја кластера

Једна од највећих предности хијерархијског кластеровања је визуелна репрезентација процеса спајања путем дендрограма, која елиминише потребу за "слепим" погађањем броја кластера.

(Овде убацујеш графикон дендрограма из свог Jupyter Notebook-а)

Анализом генерисаног дендрограма (Слика ??), где х-оса представља појединачне инстанце, а у-оса Еуклидско растојање при којем долази до спајања (повећање инерције), уочава се место најдуже вертикалног скока без хоризонталних пресека. Оптимално пресецање (енгл. cutting the tree) на том нивоу недвосмислено резултује креирањем 5 дистинктних макро-кластера. Овај корак је служио као чврст математички доказ да је емпиријски избор $k=5$ у претходном K-Means моделу био инхерентно тачан.

Након потврде кроз дендрограм, примењена је класа `AgglomerativeClustering(n_clusters=5)`, а резултати су додатно визуелизовани применом t-SNE технике у дводимензионалном простору.

(Овде убацујеш графикон t-SNE пројекције за Agglomerative)

5.3.3 Методологија интерпетације семантичких кластера

Како би се математички кластери превели у стварне економске профиле послова, било је неопходно екстраховати кључне речи (токени). Међутим, директна екстракција из 100-димензионалног SVD простора није могућа, јер латентне компоненте више не представљају конкретне речи енглеског језика.

Да би се овај проблем превазишао, примењена је напредна методологија "мапирања уназад" (енгл. Reverse Mapping):

1. За сваки индуковани кластер, издвојени су индекси свих огласа који му припадају.
2. Користећи те индексе, приступљено је оригиналној проређеној TF-IDF матрици пре SVD редукције (која садржи 5000 стварних токена).
3. Израчунат је просечни TF-IDF вектор за тај кластер (`cluster_vectors.mean(axis=0)`).
4. Редоследом сортирања просечних тежина, издвојени су доминантни термини за сваку групу.

Анализом ових термина утврђено је следеће раздвајање тржишта:

- **Кластер 0 (ИТ & Мреже):** Укључује термине `network`, `security`, `data`, `manage`, `monitor`. Кластер окупља мрежне инжењере и стручњаке за сајбер безбедност.
- **Кластер 1 (Инжењеринг и архитектура):** Садржи термине `design`, `planning`, `analysis`, `architecture`.

- **Кластер 2 и 3 (Маркетинг, аналитика и продаја):** Међусобно сродни кластери који садрже media, social, sales, demand, marketing. Занимљиво је да хијерархијски модел блиско повезује дигитални маркетинг и директну продају на гранама дендрограма, због великог броја заједничких комуникационих вештина.
- **Кластер 4 (UX/UI Дизајн):** Уско специјализован кластер око термина user, interaction, digital, designers, interactions, што указује на снажну диференцијацију сектора за развој корисничких интерфејса.

Оваква интерпетација потврђује да је хијерархијски модел, чак и на веома редукованом узорку података, успео да ухвати глобалну семантичку топологију JobDataSet скупа.

5.4 DBSCAN алгоритам

Док се претходно анализирани алгоритми (K-Means и хијерархијско кластеровање) ослањају на растојања између тачака и центроида како би креирали сферне партиције, DBSCAN (Density-Based Spatial Clustering of Applications with Noise) користи потпуно другачију парадигму – кластеризацију засновану на густини. Овај алгоритам посматра кластере као непрекидне регионе високе густине који су у простору раздвојени регионима ниске густине (шумом).

5.4.1 Теоријске основе алгоритма

Глава предност DBSCAN-а лежи у његовој способности да идентификује кластере произвољног геометријског облика и да аутоматски детектује аутлајере (аномалије/шум), без потребе да се број кластера k унапред дефинише. Рад алгоритма је контролисан са два кључна хиперпараметра:

1. ϵ (Епсилон): Радијус околине која се посматра око сваке појединачне тачке.
2. MinPts (Минимум тачака): Минималан број инстанци који мора да се налази унутар ϵ -околине да би се тај регион сматрао густим.

На основу ова два параметра, све тачке у скупу података дефинишу се у три категорије:

- **Језгрене тачке (енгл. Core points):** Тачка x је језгро ако њена ϵ -околина, дефинисана као $N_\epsilon(x) = \{y \in D \mid d(x, y) \leq \epsilon\}$, садржи најмање MinPts тачака (укључујући и саму тачку x).
- **Граничне тачке (енгл. Border points):** Тачка која сама нема довољан број комшија у својој околини (није језгро), али се налази унутар ϵ -окоLINE неке друге тачке која јесте језгро.
- **Шум / Аутлајери (енгл. Noise):** Све тачке које нису ни језгрене ни граничне.

Процес изградње кластера се математички заснива на концепту густинске достижности (енгл. density-reachability) и густинске повезаности (енгл. density-connectivity). Тачка p је директно густински достижна из тачке q ако припада њеној околини и ако је q језгро. Надаље, две тачке p и s су густински повезане ако постоји ланац језгрених такава преко којих се може доћи од једне до друге, што омогућава ширење кластера дуж региона конзистентне густине.

5.4.2 Обрада улазних података и изазов одређивања параметара

Примена DBSCAN-а над JobDataSet скупом извршена је над редукованим простором од 100 SVD компоненти коришћењем класе DBSCAN из библиотеке scikit-learn. Највећи истраживачки изазов код овог алгоритма представља правилан избор хиперпараметара, јер чак и минималне промене у вредности ϵ могу довести до тога да алгоритам цео скуп података споји у један огроман кластер или, насупрот томе, да све тачке прогласи за шум.

За одређивање оптималног ϵ параметра искоришћена је метода графикана k -удаљености (енгл. k -distance graph). Прво је за сваку тачку израчунато растојање до њеног k -тог најближег комшије (где је узето $k = \text{MinPts} = 200$), а затим су те удаљености сортиране у растућем поретку и приказане на

графикону. Вредност на којој графикон показује нагли прелом (енгл. knee или elbow) узима се као почетни епсилон, јер тачка прелома раздваја промене у локалним густинама скупа.

5.4.3 Анализа добијених резултата и визуелизација

Након покретања алгоритма са фино подешеним параметрима, извршена је пројекција лабела у дводимензионални простор помоћу t-SNE алгоритма ради детаљне визуелне инспекције.

(Овде убацујеш свој графикон који приказује t-SNE пројекцију за DBSCAN)

Анализом резултата приказаних на Слици ??, уочава се специфично понашање DBSCAN-а које се значајно разликује од претходних модела. Алгоритам је генерисао мали број веома великих и густих макро-кластера, док је значајан део података означио лабелом -1, што представља шум.

Повратно мапирање токена из оригиналне TF-IDF матрице за тачке које су проглашене за шум открило је занимљиве семантичке карактеристике. Садржај огласа означених као шум не представља стварну грешку или неконзистентност у скупу података, већ је реч о уско специфичним пословним нишама или хибридним позицијама (нпр. огласи који комбинују вештине из уметничког дизајна, напредног инжењерства и специфичног правног менаџмента). С обзиром на то да су такви огласи ретки у укупном корпусу од 1.6 милиона инстанци, они у високодимензионалном простору остају просторно изоловани, па их DBSCAN исправно изолује од мејнстрим економских категорија.

5.4.4 Евалуација алгоритма у контексту текстуалних података

Примена овог алгоритма довела је до следећих закључака у погледу предности и мана:

- **Предности:** Изванредна способност издвајања атипичних огласа за посао (шума). У реалним системима, ова

карактеристика се може успешно искористити за детекцију нових, ретких трендова на тржишту рада или за чишћење скупа података од екстремних вредности пре примене других модела.

- **Недостаци:** DBSCAN се суочава са озбиљним проблемима када ради са подацима који имају варијабилну густину. Како текстуални подаци након SVD редукције природно пате од неравномерне густине (поједини сектори послова су генерички и масовни, док су други природно дифузни), јединствени глобални параметар ϵ није у стању да подједнако успешно дефинише границе свих кластера истовремено. Такође, рачунање матрице суседства за велики број тачака изискује високу процесорску снагу.

5.5 Гаусови модели мешавине (Gaussian Mixture Models - GMM)

Док сви претходно разматрани алгоритми (K-Means, хијерархијско кластеровање и DBSCAN) имплементирају концепт такозваног "тврдог" кластерисања (енгл. Hard Clustering) – где свака инстанца стриктно припада једном кластеру или шуму, Гаусови модели мешавине (GMM) уводе вероватносни, односно "меки" приступ (енгл. Soft Clustering). Овај модел препознаје да огласи за посао на стварном тржишту често имају интердисциплинарни карактер, због чега свакој инстанци додељује вероватноћу припадности сваком од дефинисаних кластера.

5.5.1 Теоријске основе и ЕМ алгоритам

GMM представља параметарски вероватносни модел који претпоставља да су сви подаци у скупу генерисани из мешавине коначног броја Гаусових (нормалних) расподела са непознатим параметрима. Математички, функција густине вероватноће за вектор обележја x дефинисана је као линеарна

комбинација K Гаусових компоненти:

$$p(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$$

Где су π_k тежински коефицијенти мешавине за које важи

$$\sum_{k=1}^K \pi_k = 1 \quad \text{и} \quad \pi_k \geq 0$$

Свака појединачна компонента $\mathcal{N}(x \mid \mu_k, \Sigma_k)$ представља мулти-варијатну Гаусову расподелу:

$$\mathcal{N}(x \mid \mu_k, \Sigma_k) = \frac{1}{(2\pi)^{d/2} |\Sigma_k|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) \right)$$

где је d димензионалност простора, μ_k је вектор средњих вредности (центар компоненте), а Σ_k је коваријациона матрица која дефинише облик, оријентацију и елипсоидни волумен кластера.

Оптимизација параметара модела (π_k, μ_k, Σ_k) врши се итеративно применом Емпиријског ЕМ алгоритма (енгл. Expectation-Maximization):

1. **Е-корак (Очекивање):** Израчунава се постериорна вероватноћа (одговорност компоненте) да k -ти кластер генерише инстанцу x_i , на основу тренутних параметара:

$$\gamma_i(k) = \frac{\pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_i \mid \mu_j, \Sigma_j)}$$

2. **М-корак (Максимизација):** Користећи добијене вероватноће $\gamma_i(k)$ као тежине, поново се израчунавају (ажурирају) параметри π_k , μ_k и Σ_k тако да се максимизује функција логаритамске веродостојности (енгл. Log-Likelihood) целог скупа.

Кораци се понављају до постизања конвергенције.

5.5.2 Конфигурација модела и коваријационе матрице

Модел је имплементиран кроз класу GaussianMixture са бројем компоненти фиксираним на $K=5$, што омогућава директно поређење са K-Means резултатима. Кључни хиперпараметар који суштински утиче на сложеност модела је тип коваријационе матрице (covariance_type).

С обзиром на то да рад са пуном коваријационом матрицом (full) захтева процену огромног броја параметара у високодимензионалном простору, што доводи до нумеричке нестабилности и преприлагођавања (енгл. Overfitting), модел је трениран искључиво над редукованим простором од 100 SVD компоненти. Одабир дијагоналне или сферне коваријационе структуре омогућио је брзу конвергенцију алгорита унутар задовољавајућих граница рачунарске сложености.

5.5.3 Анализа сигурности модела (Confidence) и визуелизација

Након што је алгорита успешно конвергирао, израчуната је матрица постериорних вероватноћа за све инстанце. Као коначни лабел кластера одабрана је компонента са максималном вредношћу вероватноће за дати оглас.

Да би се извршила дубља евалуација модела, уведена је нова метрика – сигурност модела (енгл. Confidence), која је дефинисана као максимална вредност вероватноће коју инстанца остварује унутар додељеног кластера:

$$\text{Confidence}(x_i) = \max_k \gamma_i(k)$$

Просечна сигурност модела над целим узорком даје јасну слику о томе колико су границе између кластера семантички оштре. Висока вредност просечне сигурности имплицира да алгорита са великом извесношћу додељује огласе одређеним групама, односно да се већина инстанци налази близу Гаусових центара.

Резултати су визуелизовани пројекцијом вероватносних додела у дводимензионални простор помоћу t-SNE технике.

(Овде убацујеш свој графикон који приказује t-SNE пројекцију за GMM) Анализом Слике ?? уочава се да су пози-

ције центара кластера веома сличне онима код K-Means алгорита, што је и теоријски очекивано јер се K-Means може посматрати као гранични случај GMM-а са сферним коваријансама чија варијанса тежи нули. Међутим, предност GMM-а се огледа у прецизнијем моделирању прелазних зона. Огласи који обухватају мешовите вештине (нпр. "Дата Аналитичар" који захтева и познавање ИТ технологија и пословне аналитике/маркетинга) заузимају међупросторе на графикону и имају нижу вредност појединачне сигурности (confidence), чиме модел верно рефлектује реалну преклапајућу природу категорија на тржишту рада.

5.6 Упоредна анализа примењених алгоритама

Након спроведене експерименталне евалуације пет различитих алгоритама ненадгледаног машинског учења над Job-DataSet скупом података, могуће је извести закључке о њиховој рачунарској ефикасности, геометријским претпоставкама и способности генерализације. У Табели 5.1 приказан је систематизован преглед кључних карактеристика сваког примењеног модела.

Алгоритам	Временска сложеност	Геометрија кластера	Детекција шума	Кључни хиперпараметри
K-Means	$\mathcal{O}(n \cdot k \cdot I \cdot d)$	Сферни	Лоша	Број кластера (k)
Mini-Batch K-Means	$\mathcal{O}(b \cdot k \cdot I \cdot d)$	Сферни	Лоша	k , величина узорка (b)
Agglomerative	$\mathcal{O}(n^2 \log n)$ до $\mathcal{O}(n^3)$	Различити (хијерархија)	Осетљив	Број кластера или праг
DBSCAN	$\mathcal{O}(n \log n)$ до $\mathcal{O}(n^2)$	Произвољни	Одлична	ϵ , $MinPts$
GMM	Зависи од коваријансе	Елипсоидни (вероватносни)	Лоша	K , тип коваријансе

Табела 5.1: Упоредни преглед карактеристика примењених алгоритама кластеризације

Анализа указује на то да не постоји универзално најбољи алгоритам, већ оптималан избор директно зависи од специфичног циља истраживања. За потребе брзе и стабилне

макро-економске сегментације комплетног тржишта рада (преко 1.6 милиона огласа), Mini-Batch K-Means се убедљиво издвојио као најпрактичније решење, нудећи најбољи компромис између времена извршавања и очувања унутаркластерске инерције.

С друге стране, уколико је фокус на дубинском разумевању семантичких веза и преклапања између различитих пословних сектора, Хијерархијско кластеровање (путем анализе дендрограма) и GMM (путем анализе сигурности модела и меких граница) пружају знатно супериорнији теоријски увид, иако захтевају рад са редукованим узорцима података услед своје хардверске захтевности. Коначно, DBSCAN је доказао своју вредност као моћан алат за детекцију екстремних вредности (енгл. Outlier detection), успешно изолујући ретке пословне нише и мултидисциплинарне позиције које одступају од стандардних категорија.

Глава 6

Закључак

У овом раду спроведена је свеобухватна анализа и семантичка сегментација тржишта рада применом напредних техника истраживања података и ненадгледаног машинског учења. Кроз студију случаја над масивним JobDataSet скупом података, демонстриран је комплетан животни циклус једног пројекта из области науке о подацима – од иницијалне обраде неструктурираног текста до екстракције скривеног економског знања.

Процес препроцесирања потврдио је да квалитет излазних резултата алгоритама директно зависи од ригорозности припреме параметара. Комбинација TF-IDF векторзације за нормализацију текстуалних описа огласа и One-Hot енкодирања за категоријске променљиве, резултовала је високодимензионалним простором који је успешно компресован применом Truncated SVD методе. Ова редукција не само да је елиминисала статистички шум, већ је драстично убрзала време конвергенције свих накнадних модела.

Примена пет различитих алгоритама кластеризације открила је комплексну топологију података. Док су партициони модели попут K-Means-а ефикасно издвојили доминантне глобалне секторе (ИТ, финансије, здравство), хијерархијски приступ и Гаусови модели мешавине (GMM) омогућили су детекцију финијих семантичких прелаза и преклапања вештина између сродних занимања. Додатно, алгоритам заснован на густини (DBSCAN) показао се као одличан механизам за идентификацију ретких и хибридних радних позиција.

Ово истраживање доказује да се неструктурирани текстуални подаци могу успешно математички моделовати како би

се аутоматизовано препознали обрасци на тржишту рада. Овакви системи имају огромну практичну примену, почевши од аутоматизације HR процеса у компанијама, па све до развоја напредних препоручивачких система на платформама за запошљавање, који би у реалном времену повезивали кандидате са оптималним пословним приликама.

Библиографија

- [1] R. S. Rana, "Job Description Dataset," Kaggle, 2023. [Online]. Available: <https://www.kaggle.com/datasets/ravindrasinghrana/job-description-dataset>.
- [2] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011.
- [3] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York: Springer, 2006.
- [4] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009.
- [5] G. Salton and M. J. McGill, *Introduction to Modern Information Retrieval*. New York: McGraw-Hill, 1983.
- [6] M. W. Berry, S. T. Dumais, and G. W. O'Brien, "Using Linear Algebra for Intelligent Information Retrieval," *SIAM Review*, vol. 37, no. 4, pp. 573-595, 1995.
- [7] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, "A density-based algorithm for discovering clusters in large spatial databases with noise," in *Proceedings of the Second International Conference on Knowledge Discovery and Data Mining (KDD)*, 1996, pp. 226-231.
- [8] L. van der Maaten and G. Hinton, "Visualizing Data using t-SNE," *Journal of Machine Learning Research*, vol. 9, pp. 2579-2605, 2008.